

Datamanagement & Analytics

Prof. Dr. André Drews

Fachbereich Maschinenbau und Wirtschaft

08. Juni 2026

- nur für den Gebrauch innerhalb des Kurses -

Vorlesungskapitel 9


- Business Intelligence und Business Analytics -

Lernziele

- Kompetenz Business Intelligence
- Kompetenz Business Analytics: Deskriptive Analyse
- Kompetenz Business Analytics: Diagnostische Analyse
- Kompetenz Business Analytics: Prediktive Analyse
- Kompetenz Business Analytics: Prescriptive Analyse

1. Business Intelligence und Business Analytics
2. Deskriptive Analytics
3. Diagnostische Analytics
4. Prediktive Analytics
5. Präskriptive Analytics
6. Knowledge Discovery in Databases (KDD)

Business Analytics versus Business Intelligence



Zentrale Unterscheidung

Business Intelligence (BI) ist ein umfassendes Konzept zur Sammlung, Integration, Analyse und Bereitstellung von Unternehmensdaten.

Descriptive Analytics ist eine analytische Disziplin innerhalb von Business Analytics, die vergangene und aktuelle Daten beschreibt und visualisiert.

Ziel: Bereitstellung entscheidungsrelevanter Informationen.

Typische Komponenten:

- Datenintegration (ETL/ELT)
- Data Warehouse
- Data Marts
- Reporting
- Dashboards
- OLAP-Analysen
- Datenvisualisierung

BI beantwortet primär die Frage:

„Welche Informationen benötigen Entscheidungsträger?“

Ziel: Beschreibung und Zusammenfassung von Daten.

Typische Aufgaben:

- Berechnung von KPIs
- Trendanalysen
- Aggregation von Daten
- Berichte und Dashboards
- Visualisierung historischer Entwicklungen

Descriptive Analytics beantwortet die Frage:

„Was ist passiert?“

	Business gence	Intelli-	Descriptive Analyt- ics
Ebene	Management- und Sys- temkonzept		Analytische Methode
Ziel	Daten- und Informa- tionsversorgung		Beschreibung von In- formationen/Daten
Fokus	Datenbereitstellung und Reporting		Analyse historischer und gegenwärtiger Daten
Technologien	ETL, DWH, OLAP, Re- porting		KPIs, Reports, Dash- boards
Leitfrage	Welche Informationen werden benötigt?		Was ist passiert?

Business Intelligence

Data Integration → Data Warehouse → Reporting →
Descriptive Analytics

Merksatz

Business Intelligence stellt die Infrastruktur und Prozesse zur Informationsversorgung bereit.

Descriptive Analytics nutzt diese Informationen, um vergangene und aktuelle Geschäftsentwicklungen zu beschreiben.

Ein Unternehmen betreibt ein Data Warehouse und erstellt regelmäßig Reports.

Business Intelligence:

- Integration von ERP-, CRM- und Webshop-Daten
- Speicherung im Data Warehouse
- Bereitstellung von Dashboards

Descriptive Analytics:

- Analyse der Umsatzentwicklung
- Ermittlung der Top-Kunden
- Darstellung regionaler Verkaufszahlen

BI liefert die Datenbasis, Descriptive Analytics erzeugt daraus Erkenntnisse.

Kennzahlen:

- Einzelne quantitative Messgrößen
- Beschreiben einen bestimmten Sachverhalt
- Dienen der Messung, Steuerung und Kontrolle
- Können absolut oder relativ sein

Beispiele:

- Lagerbestand
- Durchlaufzeit
- Liefertermintreue

Kennzahlen definieren

Absolute Kennzahlen:

$$K_{abs} = x$$

Beispiel:

Lagerbestand = 2500 Stück

Relative Kennzahlen:

$$K_{rel} = \frac{x}{y}$$

Beispiel:

$$\text{Liefertermintreue} = \frac{\text{Pünktliche Lieferungen}}{\text{Gesamtlieferungen}} \cdot 100$$

Beispiel 1 - Liefertermintreue (LTT):

$$\text{LTT} = \frac{\text{Anzahl rechtzeitig angekommener Lieferungen}}{\text{Gesamtanzahl Lieferungen}} \cdot 100 = \frac{4750}{5000} \cdot 100 = 95\%$$

- Interpretation:
 - ▶ 95% der Lieferungen kommen rechtzeitig an.

Beispiel 2 - Lagerumschlag (LU):

$$\text{LU} = \frac{\text{Jahresverbrauch}}{\text{durchschnittlicher Lagerbestand}} = \frac{12000}{2000} = 6$$

- Interpretation:
 - ▶ Der Lagerbestand wird durchschnittlich sechsmal pro Jahr umgeschlagen.

Zeitliche Entwicklung einer einzelnen Kennzahl

Monat	Liefertermintreue
Jan	97%
Feb	96%
Mär	94%
Apr	91%

Erkenntnis:


→ sinkende Servicequalität.

Kennzahlen visualisieren

- Absolute Kennzahlen lassen sich sehr gut über Säulen oder Balkendiagramme abbilden
- Relative Kennzahlen können gut über Kuchendiagramme, Säulen oder Balkendiagramme dargestellt werden.

Beispiel:

Liefertermintreue über mehrere Monate als Liniendiagramm.



Nutzen:

- Trends schnell erkennen
- Zielabweichungen sichtbar machen
- Unterstützung von Entscheidungen

- Mehrere logisch verknüpfte Kennzahlen
- Gemeinsame Bewertung eines Prozesses
- Berücksichtigung von Ursache-Wirkungs-Beziehungen
- Unterstützung der Unternehmenssteuerung

Ziel:

Zusammenführen mehrerer Kennzahlen zu einem Gesamtsystem.

Nutzen:

- Ganzheitliche Bewertung
- Vermeidung isolierter Betrachtungen
- Unterstützung strategischer Entscheidungen

Beispiel Logistik:

Servicequalität

- Liefertermintreue
- Reklamationsquote

Effizienz

- Durchlaufzeit
- Kommissionierleistung

Wirtschaftlichkeit

- Lagerkosten
- Transportkosten

Kennzahlensystem berechnen

Kennzahl	Wert
Liefertermintreue	95%
Lagerumschlag	6
Durchlaufzeit	2 Tage
Transportkosten	1,50 €

Ergebnis:

Mehrere Kennzahlen liefern gemeinsam ein umfassendes Bild der Logistikleistung.

Kennzahl	Soll	Ist
Liefertermintreue	95%	91%
Lagerumschlag	5	6
Durchlaufzeit	3 Tage	2 Tage
Transportkosten	1,40 €	1,50 €

Erkenntnisse:

- Servicequalität sinkt
- Effizienz steigt
- Kosten steigen

Visualisierung mehrerer Kennzahlen in einem Dashboard.

Logistisches Beispiel:

- Liefertermintreue: 95
- Lagerumschlag: 6
- Reklamationsquote: 2
- Transportkosten: 1,50 €

Nutzen:

- Ganzheitlicher Überblick
- Erkennen von Zielkonflikten
- Unterstützung von Managemententscheidungen


Business Intelligence Reporting umfasst verschiedene Formen der Informationsbereitstellung und Entscheidungsunterstützung.

Berichtsform	Primärer Zweck
Dashboards	Operatives Monitoring und Visualisierung von KPIs
Standardberichte	Regelmäßige Informationsversorgung von Stakeholdern (z.B. .pdf)
Ad-hoc-Analysen	Untersuchung spezifischer Fragestellungen
Scorecards	Bewertung der Zielerreichung anhand von Kennzahlen
Alerts	Automatische Benachrichtigung bei kritischen Ereignissen

Ziel: Kontinuierliches Monitoring von Geschäftsprozessen.

- Interaktive Visualisierung von Kennzahlen (KPIs)
- Unterstützung operativer Entscheidungen
- Filter-, Drill-down- und Self-Service-Funktionen
- Häufig mit aktuellen oder nahezu Echtzeitdaten

Beispiel: Vertriebsdashboard mit Umsatz, Gewinn, Kundenzahl und regionaler Performance.



Ziel: Regelmäßige und konsistente Informationsbereitstellung.

- Periodisch erzeugte Berichte
- Typische Intervalle: täglich, wöchentlich, monatlich
- Verteilung als PDF, Excel-Datei oder Web-Report
- Hohe Standardisierung und Vergleichbarkeit

Beispiel: Monatlicher Management-Report für die Geschäftsführung.

Ziel: Beantwortung konkreter Fach- und Managementfragen.

- Nicht vorab definierte Auswertungen
- Flexible Exploration von Datenbeständen
- Häufig durch Fachanwender oder Data Analysts durchgeführt
- Unterstützt Ursachen- und Trendanalysen


Beispiel: „Warum sind die Verkäufe in Norddeutschland im Mai eingebrochen?“

Ziel: Messung der Zielerreichung und strategischen Performance.

- Verknüpfung von Kennzahlen mit Unternehmenszielen
- Fokus auf Soll-Ist-Vergleiche
- Unterstützung des Performance Managements
- Häufig mit Ampel- oder Statusindikatoren

Beispiel: Balanced Scorecard zur Steuerung strategischer Unternehmensziele.

Balance Score Card



Ziel: Frühzeitige Reaktion auf kritische Ereignisse.

- Automatisch ausgelöste Benachrichtigungen
- Ereignis- oder schwellenwertbasiert
- Unterstützung eines proaktiven Managements
- Versand per E-Mail, Messenger oder BI-System

Beispiel: Automatische Meldung bei Unterschreitung eines Umsatz- oder Lagerbestandsgrenzwerts.

1. Business Intelligence und Business Analytics
2. Deskriptive Analytics
3. Diagnostische Analytics
4. Prediktive Analytics
5. Präskriptive Analytics
6. Knowledge Discovery in Databases (KDD)

Leitfrage: Warum ist ein beobachtetes Ereignis eingetreten?

Diagnostic Analytics geht über die reine Beschreibung von Daten hinaus und analysiert Ursachen, Zusammenhänge und Einflussfaktoren.

Methodenkategorien

- Explorative Analyse
 - ▶ Drill-Down
 - ▶ Slice-and-Dice (OLAP)
- Abweichungs- und Ursachenanalyse
 - ▶ Varianzanalyse
 - ▶ Root Cause Analysis
- Statistische Verfahren
 - ▶ Korrelationsanalyse
 - ▶ Regressionsanalyse
- Muster- und Strukturerkennung
 - ▶ Clusteranalyse
 - ▶ Process Mining

Grundidee

Schrittweise Zerlegung aggregierter Kennzahlen in detailliertere Ebenen.

Beispiel:

Umsatz → Region → Produktgruppe → Kunde

Anwendungsfälle

- Analyse von Umsatzrückgängen
- Lokalisierung von Qualitätsproblemen
- Identifikation regionaler Unterschiede

Nutzen

Eingrenzung von Problemursachen durch zunehmende Detailtiefe.

Grundidee

Analyse eines Datenbestands aus unterschiedlichen Dimensionen.

Typische Dimensionen:

- Zeit
- Region
- Kunde
- Produkt
- Vertriebskanal

Ziel

Identifikation auffälliger Muster und möglicher Ursachen.

Grundidee

Vergleich von Soll-, Plan- oder Referenzwerten mit Ist-Werten.

Kennzahl	Soll	Ist	Abweichung
Umsatz	10 Mio.	8 Mio.	-20%
Gewinn	2 Mio.	1.5 Mio.	-25%

Fragestellungen

- Wo treten die größten Abweichungen auf?
- Welche Faktoren erklären die Differenzen? (eventuell auch fundamental/fachlich)

Ziel

Ermittlung der eigentlichen Ursache eines Problems.

Typische Verfahren


- 5-Why-Methode
- Ishikawa-Diagramm
- Fehlerbaumanalyse

Beispiel:


1. Umsatzrückgang
2. Weniger Bestellungen
3. Lieferverzögerungen
4. Lieferantenengpass
5. Fehlende Zweitlieferanten


Nutzen


Identifikation struktureller statt symptomatischer Probleme.



Ishikawa Diagramm – Beispiel







Fragestellung

Besteht ein statistischer Zusammenhang zwischen zwei Variablen?

Pearson-Korrelationskoeffizient:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2} \sqrt{\sum (y_i - \bar{y})^2}}$$

Interpretation:

- $r = 1$: perfekte positive Korrelation
- $r = 0$: kein linearer Zusammenhang
- $r = -1$: perfekte negative Korrelation

Wichtig:

Korrelation ist kein Beweis für Kausalität.

Ziel

Quantifizierung des Einflusses mehrerer Variablen auf eine Zielgröße.

Lineares Modell:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \varepsilon$$

Beispiel:

- Zielvariable: Umsatz
- Einflussgrößen:
 - ▶ Preis
 - ▶ Marketingbudget
 - ▶ Lieferzeit

Nutzen

Messung und Bewertung von Einflussfaktoren.

Grundidee

Aufteilung eines Datenbestands in möglichst homogene Gruppen.

Ziel:

- hohe Ähnlichkeit innerhalb eines Clusters
- geringe Ähnlichkeit zwischen Clustern

Typische Anwendungen:

- Kundensegmentierung
- Marktsegmentierung
- Produktsortimentsanalyse
- Betrugserkennung

Clusteranalyse gehört zum **Unsupervised Learning**.

Algorithmus

1. Wahl der Clusteranzahl k
2. Initialisierung von k Zentroiden $\mu_i^{t=t'}$
3. Zuordnung der Objekte zum nächsten Zentrum $\mu_i^{t=t'}$
4. Aktualisierung der Zentren $\mu_i^{t=t'+1}$
5. Iteration bis zur Konvergenz

Optimierung:

$$J = \sum_{i=1}^k \sum_{x \in C_i} |x - \mu_i|^2$$

Ziel ist die Minimierung der Intra-Cluster-Varianz.

Problem

Wie viele Cluster sollen gebildet werden?

Vorgehen:

1. Berechnung von J für verschiedene Werte von k
2. Darstellung als Kurve
3. Identifikation des Knickpunkts

Interpretation:

Der optimale Wert von k liegt häufig am Punkt abnehmender Grenzerträge ("Elbow").

Grundidee

Analyse realer Geschäftsprozesse auf Basis von Event Logs.

Typische Fragestellungen:

- Wo entstehen Engpässe?
- Welche Prozessschritte verursachen Verzögerungen?
- Wo weichen reale Prozesse vom Soll-Prozess ab?

Anwendungsfelder:

- Order-to-Cash
- Procure-to-Pay
- Produktionsprozesse
- Logistikprozesse

Methode	Primäres Ziel
Drill-Down	Lokalisierung von Ursachen
Slice-and-Dice	Mehrdimensionale Exploration
Abweichungsanalyse	Soll-Ist-Vergleich
Root Cause Analysis	Ursachenidentifikation
Korrelationsanalyse	Zusammenhangsanalyse
Regressionsanalyse	Quantifizierung von Einflussfaktoren
Clusteranalyse	Segmentierung von Objekten
Process Mining	Analyse realer Prozesse

1. Business Intelligence und Business Analytics
2. Deskriptive Analytics
3. Diagnostische Analytics
- 4. Prediktive Analytics**
5. Präskriptive Analytics
6. Knowledge Discovery in Databases (KDD)

Definition Stochastischer Prozess

In der Sei (Ω, Σ, p) ein Wahrscheinlichkeitsraum. Sei $T \subset R_+$ eine geordnete Indexmenge. Im diskreten Fall gilt z.B.

$T = \{0, 1, 2\}$, im stetigen Fall $T = \{0, 0.12313, 0.12524, \dots\}$.


Ein stochastischer Prozess ist eine Familie (Folge von Mengen nach Indexmenge geordnet) von Zufallsvariablen

$$S_t : \Omega \rightarrow R \text{ mit } t \in T$$

Für die Abbildung gilt allgemein:

$$S : \Omega \times T \rightarrow R$$

Drei Realisierungen eines Stochastischen Prozesses



Quelle: [https://www.uni-](https://www.uni-goettingen.de/de/document/download/bced8d2cf092e3487839c365955c85f2.pdf/ZRSkript_Teil2_Okt09.pdf)

[goettingen.de/de/document/download/bced8d2cf092e3487839c365955c85f2.pdf/ZRSkript_Teil2_Okt09.pdf](https://www.uni-goettingen.de/de/document/download/bced8d2cf092e3487839c365955c85f2.pdf/ZRSkript_Teil2_Okt09.pdf)

Drei Realisierungen eines Stochastischen Prozesses bei konstantem Erwartungswert $E_t(x)$ und konstanter Varianz $V_t(x)$ pro Zeitschritt t .

- nur für den Gebrauch innerhalb der Vorlesung -

Definon Autokorrelation

- Die Autokorrelation beschreibt die paarweise Abhängigkeit zwischen Zeitpunkt x_t und x_{t-k} aufsummiert über die gesamte Zeitreihe. Dabei entspricht $t = 1$ dem Zeitreihenstart und $t = N$ dem Zeitreihenende und k dem Zeitreihenversatz.
- Ein Stochastischer Prozess mit Autokorrelation weist eine Abhängigkeit zwischen den Zeitwerten auf. Dies bedeutet es existiert ein "Gedächtnis". Einen zufällige Störung wird durch diese Abhängigkeit in der Zeit weiterprogragiert.

Beispiel: Der Abschlusskurs einer Aktie hat einen Einfluss auf den Einstiegskurs des Folgetags. Eine Aktie wird nie maximale Sprünge aufweisen können. Zufällige Störungen werden durch die Zeit weiterpropagiert.

Schreibweise: Der Lag-Operator kann als Kurzschreibweise für den i -ten Zeitschritt in die Vergangenheit genutzt werden:

$$L_i x_t = x_{t-i}, \text{ z.B. : } L_5 x_t = x_{t-5}$$

Autokorrelationsfunktion (ACF):

$$\text{ACF}(k) = \frac{\sum_{t=1}^{N-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{\sum_{t=1}^N (x_t - \bar{x})^2}, \quad k = 0, 1, \dots, N-1$$

- $\text{ACF}(k)$ misst die Korrelation der Zeitreihe mit sich selbst bei Verzögerung k .
- Die Summation im Zähler hat $N - k$ Terme.
- $t = 1$ ist der Anfang, $t = N$ das Ende der Zeitreihe.

Autokorrelationslänge:

- Gibt an, wie viele Zeitschritte die Autokorrelation signifikant von Null verschieden bleibt.
- Maß für das "Gedächtnis" des Prozesses.
- Formal oft definiert als der kleinste k , bei dem $|ACF(k)|$ unter einen Schwellenwert fällt (z.B. statistische Signifikanzgrenze).

Beispiel Berechnung der Autokorrelationsfunktion

Gegeben ist die Zeitreihe:

$$x = [7, 9, 4]$$

1. Mittelwert:

$$\bar{x} = \frac{7 + 9 + 4}{3} = \frac{20}{3} \approx 6,67$$

2. Varianz (Nenner der ACF):

$$\sum_{t=1}^3 (x_t - \bar{x})^2 = (7 - 6,67)^2 + (9 - 6,67)^2 + (4 - 6,67)^2 = 0,11 + 5,44 + 7,11 = 12,6$$

Beispiel Berechnung der Autokorrelationsfunktion (ACF)

3. Autokorrelationsfunktion:

$$\text{ACF}(k) = \frac{\sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}$$

ACF(1):


$$\frac{(7 - 6,67)(9 - 6,67) + (9 - 6,67)(4 - 6,67)}{12,67} = \frac{0,77 - 6,22}{12,67} = \frac{-5,44}{12,67} \approx -0$$

ACF(2):

$$\frac{(7 - 6,67)(4 - 6,67)}{12,67} = \frac{-0,88}{12,67} \approx -0,07$$

ACF(3): nicht definiert, da $n - k = 0$

Beispiel Autokorrelationsfunktion über verrauschte Sinusfunktion



Quelle: wikipedia.org

ACF(1), ... ACF(90)

Bestimmung der Autokorrelationskonfunktion in Python

```
#define data
x = [22, 24, 25, 25, 28, 29, 34, 37, 40, 44, 51, 48, 47, 50, 51]

import statsmodels.api as sm

#calculate autocorrelations
sm.tsa.acf(x)

array([ 1.          ,  0.83174224,  0.65632458,  0.49105012,  0.27863962,
        0.03102625, -0.16527446, -0.30369928, -0.40095465, -0.45823389,
       -0.45047733])

sm.tsa.acf(x, nlags=5)


array([1.0, 0.83174224, 0.65632458, 0.49105012, 0.27863962, 0.03102625])
```

Quelle: <https://www.statology.org/autocorrelation-python/>

Bestimmung der Autokorrelationsfunktion in Python

```
from statsmodels.graphics import tsaplots
import matplotlib.pyplot as plt

#plot autocorrelation function
fig = tsaplots.plot_acf(x, lags=10)
plt.show()
```



Was bedeutet Stationarität?

Intuition zu Stationarität:

Ein stationärer stochastischer Prozess ist "**zeitlich stabil**" in seinen statistischen Eigenschaften.

- **Streng stationär:** Alle Wahrscheinlichkeitsverteilungen bleiben gleich bei Zeitverschiebung
- **Schwach stationär:**
 - ▶ Erwartungswert $\mathbb{E}[X_t] = \mu$ konstant
 - ▶ Varianz $\text{Var}(X_t) = \sigma^2$ konstant
 - ▶ Kovarianz $\text{Cov}(X_t, X_{t+k})$ nur abhängig von k

Bedeutung in Zeitreihenanalyse: Stationäre stochastische Prozesse sind besonders gut analysierbar, weil ihre statistischen Eigenschaften sich nicht mit der Zeit verändern. Das vereinfacht viele mathematische und praktische Analysen erheblich.

Technische/atengetriebene Sicht auf Stochastische Prozesse: Zeitreihen

Zeitreihe

Eine Zeitreihe ist eine zeitlich geordnete Folge von Zufallsvariablen bzw. Zielfunktionswerten x_t mit $t \in [t_0, \dots, t_n]$. Stochastisch gesehen entspricht die Zeitreihe einer Realisierung eines Stochastischen Prozesses.

Eine Zeitreihe lässt sich über

$$x(t) = m(t) + p(t) + \xi(t)$$


in die Komponenten m : Trend, p : Periodizität, ξ Rauschen zerlegen.

Analyse Nicht stationärer Zeitreihen: Decomposition sklearn

```
from pandas_datareader import data as pdr
from matplotlib import pyplot as plt
import statsmodels.api as sm
```

```
data=pdr.get_data_yahoo("GOOG", start="2017-06-01", end="2020-06-01")["High"]
```

```
decomposition = sm.tsa.seasonal_decompose(data, freq=52)
decomposition.plot()
```



Zeitreihe vs Regression: Time Dependent Analysis vs. Regression

- Zeitreihenprobleme besitzen als wichtigstes feature die Zeit. Die Zielfunktion hängt entsprechend von der Zeit ab. Werden weitere features betrachtet, sind dies auch wieder Funktionen von der Zeit
↔ bei Regression können features beliebig gewählt werden.
- Methodischer Unterschied: Bei Zeitreihenanalyse wird der Fokus auf den unsystematischen/stochastischen Anteil gelegt
↔ bei Regression ist Regel der systematische Teil/Trend im Fokus.

Moving Average

- Der Moving Average wird zur Glättung von Zeitreihendaten verwendet. Kurzfristige Schwankungen oder Rauschen werden reduziert und langfristige Trends oder Muster in den Daten sollen sichtbar gemacht werden.
- Der Moving Average kann auch zur Prognose oder Vorhersage zukünftiger Werte in einer Zeitreihe verwendet werden, insbesondere wenn es sich um einen gleitenden Durchschnitt mit einer hohen Fenstergröße handelt.
- Es gibt verschiedene Varianten des Moving Average für Prognosezwecke, wie
 - ▶ den einfachen gleitenden Durchschnitt (Simple Moving Average)
 - ▶ den gewichteten gleitenden Durchschnitt (Weighted Moving Average)
 - ▶ den exponentiell geglätteten gleitenden Durchschnitt (Exponential Moving Average)

- MA ist eine einfache und oft grobe Methode, die für stabile und langfristige Trends geeignet ist. Bei stark volatilen oder unregelmäßigen Daten kann der Moving Average zu ungenauen Prognosen führen.
- Wenn eine genauere Prognose benötigt wird, sollten komplexere Zeitreihenmodell(z. B. ARIMA-Modelle) oder maschinelles Lernen (z. B. neuronale Netze) angewandt werden.

Zeitreihe als Spezialform der Regression: Time Dependent Analysis vs. Regression

- Methodik Zeitreihen:
 - ▶ Simple Moving Average (SMA)
 - ▶ Autokorrelation
 - ▶ Komponentenerlegung (Trend, Periodizität, Rauschen)
 - ▶ Moving Average (MA), Autoregressives Moving Average (ARMA), Autoregressives Integratives Moving Average (ARIMA)
 - ▶ Neuronale Netze (MLP, LSTM, ...)
- Methodik Regression:
 - ▶ Methode der Kleinsten Quadrate
 - ▶ SVM, KNN, Decision Trees
 - ▶ Neuronale Netze (MLP, ...)

Zweck der Zeitreihenanalyse und Vergleich zur Regression

- Zeitreihenanalyse dient dazu
 - ▶ den Verlauf zu prognostizieren
 - ▶ Muster im Zielfunktionsverlauf zu identifizieren
 - ▶ Zeitreihen auf wenige Größen zurückzuführen

↔ Klassische Regression dient der Korrelationsbestimmung und der Prognose der generellen Zielfunktion.

Simple Moving Average (SMA)

Gleitender Durchschnitt n -ter Ordnung: Folge arithmetischer Mittelwerte über die letzten n -Punkte:

$$m_{MA}^{(n)}(t) = \frac{1}{n} \sum_{i=0}^{n-1} x_{t-i}$$



Gewichteter und exponentieller gleitender Durchschnitt

- Gewichteter gleitender Durchschnitt:


$$m_x^{(n)}(t - \tau) = \frac{1}{n - 1} \omega_i \cdot x(t - i)$$

mit $\tau > 0$ für Vergangenheitswerte und den Gewichten ω_i .

Beispiel: $m_{BIN}(t - 1) = \frac{1}{4}x(t) + \frac{1}{2}x(t - 1) + \frac{1}{4}x(t - 2)$

- Exponentiell geglätteter Durchschnitt: jüngerer Datenpunkte werden stärker gewichtet als weiter zurückliegende:

$$m_{EMA}^{(n)}(t) = \alpha \cdot x(t) + (1 - \alpha) \cdot m_{FMA}^{(n)}(t - 1)$$



MA(q)-Modell (Moving Average Modell) - Prognose über weißes Rauschen

MA-Modell (Moving Average)


Modell zur Prognose von Zeitreihen auf Basis von Fehlertermen:

Voraussetzung: **Stationarität**

$$x_t = c + \epsilon_t + \sum_{j=1}^q b_j \epsilon_{t-j}$$

Das zu modellierende/prognostizierende Signal x_t setzt sich aus einer Konstanten (der mittleren Abweichung des Wertes x_t von den Rauschtermen), dem gegenwärtigen Rauschterm ϵ_t sowie den q vorherigen Rauschtermen ϵ_{t-j} mit den Gewichten b_j zusammen.

Vorgehen: MA-Modell (Moving Average Modell)



Quelle: [https://towardsdatascience.com/defining-the-moving-average-model-for-time-series-forecasting-in-](https://towardsdatascience.com/defining-the-moving-average-model-for-time-series-forecasting-in-thon-626781db2502)

AR-Modell

Voraussetzung: **Stationarität**

Das AR-Modell

$$x_t = c + \epsilon_t + \sum_{i=1}^p a_i x_{t-i}$$

ergibt sich aus einer Konstante c (Abweichung des Werts x_t des Rauschterms und der vorherigen p Zeitreihenwerte), einem Rauschterm ϵ_t , einem gewichteten Mittelwert der Zeitreihenwerte bis zum Zeitschritt $t - p$

- Beim MA(q)-Modell gilt $afc_i = 0 \quad \forall, i > q$
- Bei AR gilt $afc_i \neq 0$ und die afc_i Werte fallen exponential ab.

ARMA-Modell

Voraussetzung: **Stationarität**

Das ARMA Modell:

$$x_t = c + \epsilon_t + \sum_{i=1}^p a_i x_{t-i} + \sum_{j=1}^q b_j \epsilon_{t-j}$$

setzt sich aus dem MA und dem AR-Modell zusammen.

Differenzierung:

$$y'_t = y_t - y_{t-1}$$

Es gilt $y_t - y_{t-1} = \epsilon_t$, da der offset c in beiden Subtrahenden enthalten ist.

→ Durch Differenzierung verschwindet die Trendkomponente.

ARIMA-Modell

Das ARIMA-Modell entspricht dem ARMA-Modell mit Differenzierung. Hierbei gilt:

$$d = 0 : y_t = Y_t$$

$$d = 1 : y_t = Y_t - Y_{t-1}$$

$$d = 2 : y_t = (Y_t - Y_{t-1}) - (Y_{t-1} - Y_{t-2}) = Y_t - 2Y_{t-1} + Y_{t-2}$$

Modell zur Prognose von Zeitreihen:

$$y_t^d = c + \sum_{i=1}^p a_i y_{t-i}^d + \sum_{i=1}^q b_i \epsilon_{t-i}$$

mit p =number of the autoregressive terms, d =degree of first differencing involved, q =order of the moving average part.

Non-Seasonal ARIMA-Modell


Application	ARIMA type
White noise	ARIMA (0,0,0)
First Order Autoregressive	ARIMA (1,0,0)
Difference first-order model	ARIMA (0,1,0)
Difference first-order autoregressive model	ARIMA (1,1,0)
Simple exponential smooting	ARIMA (0,1,1)
Linear exponential smooting	ARIMA (0,2,2)

Moving Average sklearn

```
from pandas_datareader import data as pdr
from matplotlib import pyplot as plt
```

```
data=pdr.get_data_yahoo("GOOG", start="2017-06-01", end="2020-06-01")["High"]
data.plot()
data2=data.rolling(15).mean()
data2.plot()
```

<matplotlib.axes._subplots.AxesSubplot at 0x7f6f72760da0>




ARIMA sklearn

```
from pandas_datareader import data as pdr
from matplotlib import pyplot as plt
from statsmodels.tsa.arima_model import ARIMA
```

```
data=pdr.get_data_yahoo("GOOG", start="2017-06-01", end="2020-06-01")["High"]
split_point= len(data) - 50
dataset, validation = data[0:split_point], data[split_point:]
data.plot()
validation.plot()
```

<matplotlib.axes._subplots.AxesSubplot at 0x7f313b0c6400>



```
from statsmodels.tsa.arima_model import ARIMA
import numpy
from matplotlib import pyplot

size = int(len(data) * 0.98)
train, test = data[0:size], data[size:len(data)]
history = [x for x in train]
predictions = list()
predictionPandas = pd.DataFrame()
for t in range(len(test)):
    model = ARIMA(history, order=(2,1,0))
    model_fit = model.fit(disp=0)
    output = model_fit.forecast()
    yhat = output[0]
    predictions.append(yhat[0])
    obs = test[t]
    history.append(obs)

predictionPandas["values"] = predictions
predictionPandas.index = test.index
ax = test.plot(style="-o")
predictionPandas.plot(ax=ax, style="-s")
```

<matplotlib.axes._subplots.AxesSubplot at 0x7f31388bd278>



Vektor ARIMA-Modell

Modell zur Prognose von mehreren Zeitreihen gleichzeitig:

$$y_{1,t}^d = c + \sum_{i=1}^p a_{1,i} y_{1,t-i}^d + \sum_{i=1}^q b_{1,i} \epsilon_{1,t-i}$$

$$y_{2,t}^d = c + \sum_{i=1}^p a_{2,i} y_{2,t-i}^d + \sum_{i=1}^q b_{2,i} \epsilon_{2,t-i}$$

```
# VARMA example
from statsmodels.tsa.statespace.varmax import VARMAX
from random import random
# contrived dataset with dependency
data = list()
for i in range(100):
    v1 = random()
    v2 = v1 + random()
    row = [v1, v2]
    data.append(row)
# fit model
model = VARMAX(data, order=(1, 1))
model_fit = model.fit(disps=False)
# make prediction
yhat = model_fit.forecast()
print(yhat)
```


Time To Event

In einigen Anwendungsfällen (z.B. Medizin, predictive Maintenance) ist es wichtig festzustellen wie lange ein System funktionsfähig ist.



Kaplan-Meyer Estimator

Kaplan-Meier-Schätzer für Überlebensfunktion:

$$S(t) = \prod_{t_i \leq t} \left(1 - \frac{d_i}{n_i}\right)$$

d_i : Versuchsobjekte, bei denen das Ereignis zum Zeitpunkt t_i eingetreten ist.

n_i : Versuchsobjekte zum Zeitpunkt t_i unter Risiko



Quelle: <https://www.analyticsvidhya.com/blog/2020/12/a-brief-introduction-to-survival-analysis-and-kaplan->

ier-estimator/

1. Business Intelligence und Business Analytics
2. Deskriptive Analytics
3. Diagnostische Analytics
4. Prediktive Analytics
5. Präskriptive Analytics
6. Knowledge Discovery in Databases (KDD)

Leitfrage: Was sollten wir tun?

Prescriptive Analytics unterstützt Entscheidungen durch die Ableitung konkreter Handlungsempfehlungen auf Basis von Daten, Prognosen und Optimierungsverfahren.

Ziele

- Optimierung von Entscheidungen
- Maximierung von Nutzen oder Gewinn
- Minimierung von Kosten oder Risiken
- Automatisierung von Entscheidungsprozessen

Beispiele

- Preisoptimierung
- Produktionsplanung
- Tourenplanung
- Bestandsoptimierung

Analytics-Typ	Leitfrage	Ergebnis
Descriptive	Was ist passiert?	Transparenz
Diagnostic	Warum ist es passiert?	Ursachenverständnis
Predictive	Was wird passieren?	Prognosen
Prescriptive	Was sollten wir tun?	Handlungsempfehlungen

Prescriptive Analytics baut auf den Ergebnissen der Predictive Analytics auf.

Predictive Analytics

- Nachfrage nächste Woche: 12.000 Einheiten
- Churn-Wahrscheinlichkeit eines Kunden: 80
- Ausfallwahrscheinlichkeit einer Maschine: 30

Prescriptive Analytics

- Wie viel soll produziert werden?
- Welchem Kunden soll ein Rabatt angeboten werden?
- Wann sollte die Wartung durchgeführt werden?

Prognosen werden in konkrete Entscheidungen überführt.

Operations Research und Optimierung

- Lineare Optimierung
- Ganzzahlige Optimierung
- Nichtlineare Optimierung
- Netzwerkoptimierung

Entscheidungsunterstützung

- Entscheidungsbäume
- Nutzwertanalyse
- Multi-Kriterien-Entscheidungsverfahren

Künstliche Intelligenz

- Reinforcement Learning
- Heuristiken und Metaheuristiken

Grundidee

Bestimmung einer optimalen Entscheidung unter Nebenbedingungen.

Beispiel:

[maximiere Gewinn]

unter den Restriktionen:

[Rohstoffe $\leq$ *Verfgbarkeit*]

[Kapazität $\leq$ *Maschinenstunden*]

Typische Anwendungen:

- Produktionsplanung
- Personaleinsatzplanung
- Lageroptimierung

Fragestellung

Welcher Preis maximiert den Gewinn?

Benötigte Informationen:

- Nachfrageprognosen
- Kostenstruktur
- Preiselastizitäten

Vorgehen:

1. Nachfrage prognostizieren
2. Gewinnfunktion modellieren
3. Optimales Preisniveau bestimmen

Ergebnis:

Empfehlung eines gewinnmaximalen Preises.

Problem

Zu hohe Bestände verursachen Kosten, zu niedrige Bestände verursachen Fehlmengen.

Eingaben:

- Nachfrageprognosen
- Lagerkosten
- Bestellkosten
- Lieferzeiten

Ziel:

Bestimmung optimaler Bestellmengen und Sicherheitsbestände.

```
c = [-40, -30]
A = [[2, 1], [1, 1]]
b = [100, 80]
result = linprog( c, A_ub=A, b_ub=b)
print(result.x)
```

Bestimmung der optimalen Produktionsmengen für zwei Produkte unter Kapazitätsrestriktionen.

Ein Handelsunternehmen prognostiziert die Nachfrage der nächsten Woche.

Predictive Analytics

- Nachfrageprognose: 12.000 Einheiten

Prescriptive Analytics

- Optimale Bestellmenge
- Optimale Lagerhaltung
- Optimale Personalplanung

Die Prognose wird in konkrete Handlungsentscheidungen umgesetzt.

Kernaussage

Prescriptive Analytics beantwortet nicht nur, was passieren wird, sondern empfiehlt, welche Maßnahmen zur Erreichung eines Ziels durchgeführt werden sollten.

Typische Ergebnisse

- Optimale Preise
- Optimale Produktionspläne
- Optimale Touren
- Optimale Bestellmengen

Prescriptive Analytics verbindet Data Science, Business Analytics und Operations Research.

1. Business Intelligence und Business Analytics
2. Deskriptive Analytics
3. Diagnostische Analytics
4. Prediktive Analytics
5. Präskriptive Analytics
6. Knowledge Discovery in Databases (KDD)

Knowledge Discovery in Databases

